浙江大學
ZHEJIANG UNIVERSITY

数据库系统

minisql 小组报告

3220103422 刘韬

3220104617 周龙

2024 年 6 月 16 日

目录

1 实验分工 **3**

2 实验概述 **3**

2.1 实验目的 3

2.2 实验需求 3

2.3 实验环境 4

3 系统架构和模块概述 **5**

3.1 系统架构 5

3.2 模块概述 6

3.2.1 DiskManager 6

3.2.2 BufferPoolManager 7

3.2.3 Record Manager 8

3.2.4 Index Manager 8

3.2.5 Catalog Manager 9

3.2.6 Planner and Executor 9

3.2.7 SQL Parser 10

3.2.8 Recovery Manager 10

4 测试样例和功能测试 **11**

4.1 测试样例 11

4.2 功能测试 12

5 总结 **15**

1 实验分工

姓名	分工
刘韬	lab1（包括 bonus），lab2，lab3，系统功能调试，小组报告撰写
周龙	lab4，lab5，lab6

表 1: 实验分工

2 实验概述

2.1 实验目的

1. 设计并实现一个精简型单用户 SQL 引擎 MiniSQL，允许用户通过字符界面输入 SQL 语句实现基本的增删改查操作，并能够通过索引来优化性能。

2. 通过对 MiniSQL 的设计与实现，提高学生的系统编程能力，加深对数据库管理系统底层设计的理解。

2.2 实验需求

1. 数据类型：要求支持三种基本数据类型：`integer`，`char(n)`，`float`。

2. 表定义：一个表可以定义多达 32 个属性，各属性可以指定是否为 unique，支持单属性的主键定义。

3. 索引定义：对于表的主属性自动建立 B+ 树索引，对于声明为 unique 的属性也需要建立 B+ 树索引。

4. 数据操作: 可以通过 and 或 or 连接的多个条件进行查询，支持等值查询和区间查询。支持每次一条记录的插入操作；支持每次一条或多条记录的删除操作。

5. 使用源代码管理工具（如 Git）进行代码管理，代码提交历史和每次提交的信息清晰明确；同时编写的代码应符合代码规范，具有良好的代码风格。

需要支持的 SQL 语句 实验应当支持以下 SQL 语句：

```
create database db0;
drop database db0;
show databases;
use db0;
show tables;
```

```
create table t1(a int, b char(20) unique, c float, primary key(a, c));
create table t1(a int, b char(0) unique, c float, primary key(a, c));
create table t1(a int, b char(-5) unique, c float, primary key(a, c));
create table t1(a int, b char(3.69) unique, c float, primary key(a, c));
create table t1(a int, b char(-0.69) unique, c float, primary key(a, c));
create table student(
  sno char(8),
  sage int,
  sab float unique,
  primary key (sno, sab)
);
drop table t1;
create index idx1 on t1(a, b);
-- "btree" can be replaced with other index types
create index idx1 on t1(a, b) using btree;
drop index idx1;
show indexes;
select * from t1;
select id, name from t1;
select * from t1 where id = 1;
-- note: use left association
select * from t1 where id = 1 and name = "str";
select * from t1 where id = 1 and name = "str" or age is null and bb not null;
insert into t1 values(1, "aaa", null, 2.33);
delete from t1;
delete from t1 where id = 1 and amount = 2.33;
update t1 set c = 3;
update t1 set a = 1, b = "ccc" where b = 2.33;
quit;
execfile "a.txt";
```

2.3 实验环境

- 基于 WSL2–ubuntu 进行开发，通过 vscode 连接至 Linux 子系统.
- 基于 MacOS 进行开发，使用 clang 编译.

3 系统架构和模块概述

3.1 系统架构

最终我们向用户呈现的是一个命令行界面，用户可以通过命令行输入 SQL 语句，MiniSQL 会解析这些 SQL 语句并执行相应的操作。MiniSQL 的整体架构如下图所示：

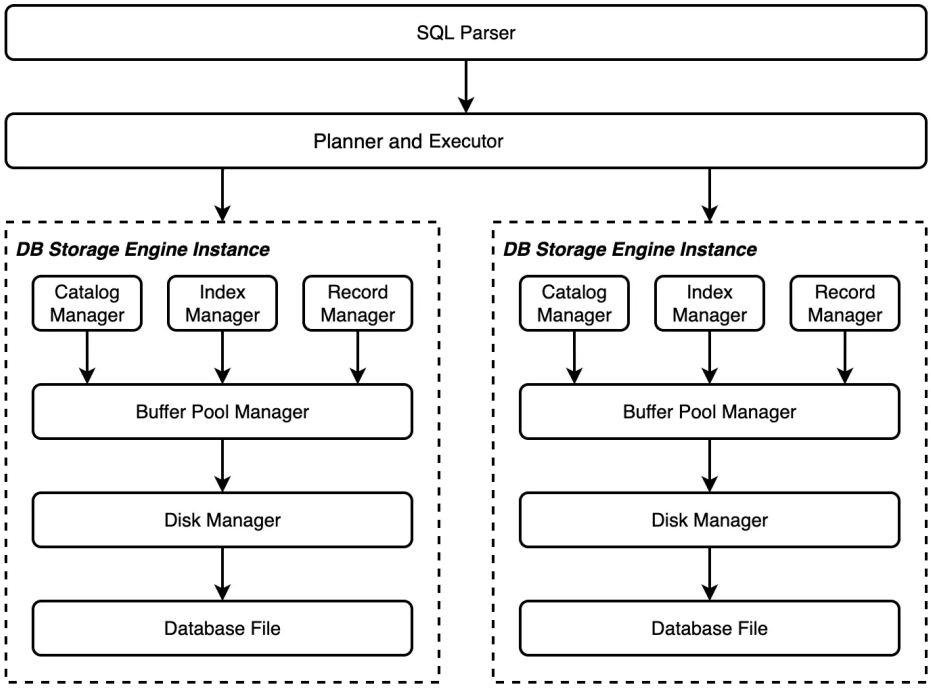

图 1: MiniSQL 系统架构

系统接收到 SQL 语句后，通过 SQL Parser 生成语法树，然后通过 executor（由 Planner and Executor 调用下层模块生成）调用 Catalog Manager、Record Manager 和 Index Manager 等模块来执行相应的操作。Catalog Manager 负责表的元数据管理，Record Manager 负责表的记录管理，Index Manager 负责索引的管理。而这三个模块都是基于 Buffer Manager 提供的缓冲区管理服务。Buffer Manager 负责缓冲区的管理，调用 Disk Manager 来读写文件。

每个 DB Storage Engine Instance 对应了一个数据库实例(即通过 CREATE DATABSAE 创建的数据库)。在每个数据库实例中，用户可以定义若干表和索引，表和索引的信息通过 Catalog Manager、Index Manager 和 Record Manager 进行维护。我们实现的系统支持使用多个数据库实例，不同的数据库实例可以通过 USE 语句切换（即类似于 MySQL 的切换数据库)。

3.2 模块概述

系统架构是自上而下的叙述系统的工作原理和工作流程，在具体实现时应当是自下而上进行模块支持。下面我们将对系统的各个模块进行介绍。详细的实现报告请参考个人报告。

3.2.1 DiskManager

DiskManager 是系统最底层的模块，负责与磁盘进行交互，负责 DB File 中数据页的分配和回收，以及数据页中数据的读取和写入。在我们的实现中为了管理数据库中的文件，我们需要实现一个对磁盘进行读写的类 DiskManager，它的功能是对数据中的 page（基本数据单元）进行 allocation 和 de allocation，执行从磁盘中进行读写 page 的操作。除了存储数据的数据页，我们还需要一些元数据来帮助和加速数据页的管理，于是位图页就自然的出现了。我们将一个位图页和它所管理的一段连续的数据页称作数据库文件中的一个分区（extent）。为了提高存储的容量，我们使用一个额外的元信息页来存储各个分区的信息。这种套娃的方式可以使磁盘文件能够维护更多的数据页信息。DiskManager 所实现的数据结构如图2所示，其中包括了数据页、位图页和元信息页。

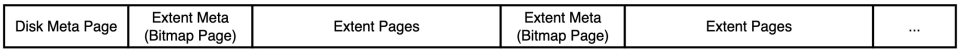

图 2: DiskManager 模块

数据页就是存储数据的基本单位，位图页用于管理数据页的分配和回收，元信息页用于存储各个分区的信息。以下是位图页的设计：

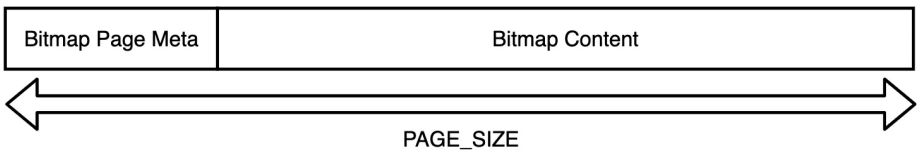

图 3: 位图页设计

bitmap page 位图页的大小与数据页的大小一致，如3所示，位图页由 Bitmap Page Meta 和 Bitmap Content 两部分组成。Bitmap Page Meta 就是位图页的元数据，含当前已经分配的页的数量（page_allocated_）以及下一个空闲的数据页 (next_free_page_)。Bitmap Content 使用 char 数组来记录数据，其容量大小是 MAX_CHARS = PageSize - 2 * sizeof(uint32_t)，每个 bit 的含义是对应的页是否被分配，一个 char 的大小是 8bits，位图页对外提供分配、回收数据页和判断数据页是否可用的接口，内部实现是对上述数组的管理。

DiskManager 具有向磁盘读写物理页，分配和回收页的功能。为了更好地管理数据，我们在前面设置了元数据页，但对于上层的程序而言，数据管理器提供的应当是连续的数据页，即逻辑页号。因此我们需要在这里对逻辑页和物理页进行映射，使得上层能够无感知地获得数据页。映射示意图4

物理页号	0	1	2	3	4	5	6	...
职责	磁盘元数据	位图页	数据页	数据页	数据页	位图页	数据页	
逻辑页号	/	/	0	1	2		3	

图 4: 逻辑页和物理页映射

3.2.2 BufferPoolManager

Buffer Manager 负责缓冲区的管理，主要功能包括：

- 根据需要，从磁盘中读取指定的数据页到缓冲区中或将缓冲区中的数据页转储（Flush）到磁盘
- 实现缓冲区的替换算法，当缓冲区满时选择合适的数据页进行替换；
- 记录缓冲区中各页的状态，如是否是脏页（Dirty Page）、是否被锁定（Pin）等；
- 提供缓冲区页的锁定功能，被锁定的页将不允许替换。

为提高磁盘 I/O 操作的效率，缓冲区与文件系统交互的单位是数据页（Page），数据页的大小应为文件系统与磁盘交互单位的整数倍。在本实验中，数据页的大小默认为4KB。

对于上述要实现的功能，我们首先需要实现缓冲区的替换算法，本实验中我们实现了 LRU 算法和 CLOCK 算法。LRU 算法是一种最近最少使用算法，即当缓冲区满时，选择最近最少使用的页进行替换。CLOCK 算法是一种近似 LRU 算法，它维护一个指针，指向最近访问的页，当缓冲区满时，选择指针指向的页进行替换。

然后我们实现了缓冲区的管理，即实现了缓冲区的初始化、读取数据页、写入数据页、将数据页标记为脏页、将数据页标记为锁定页等功能。缓冲池管理器为上层提供读取数据的接口，上层只要输入 page_id，即可获得数据页的内容。对内调用 DiskManager，将数据页读取到缓冲区中。实现了良好的封装，上层无需关心数据页的具体存储位置，只需关心逻辑页号。

在后续的开发中，涉及到页面的操作都只需要通过 BufferPoolManager 类来完成。

3.2.3 Record Manager

Record design 我们的记录包含以下几个概念：

- **Column**：用于定义和表示数据表中的某一个字段，即包含了这个字段的字段名、字段类型、是否唯一等等；
- **Schema**：用于表示一个数据表或是一个索引的结构。一个 Schema 由一个或多个的 Column 构成；
- **Field**：它对应于一条记录中某一个字段的数据信息，如存储数据的数据类型，是否是空，存储数据的值等等；
- **Row**：用于表示一条记录，即一行数据，由多个 Field 组成；

这是我们数据在数据库中的组织方式，但是为了将其持久化地存储在硬盘中，我们需要使用序列化和反序列化地方法，将其转化为字节流。

Record Manager 负责管理数据表中记录。所有的记录以堆表（Table Heap）的形式进行组织。Record Manager 的主要功能包括：记录的插入、删除与查找操作，并对外提供相应的接口。其中查找操作返回的是符合条件记录的起始迭代器，对迭代器的迭代访问操作由执行器（Executor）进行。

Table Heap 堆表是由多个数据页构成的链表，每个数据页中包含一条或多条记录，支持非定长记录的存储。不要求支持单条记录的跨页存储（即保证所有插入的记录都小于数据页的大小）。堆表中所有的记录都是无序存储的。每条记录都有一个独特的`RowId`标记其所在的位置。利用这个`RowId`，我们可以在堆表中快速定位到一条记录。table heap 的结构如下：

堆表中的每个数据页都由表头（Table Page Header）、空闲空间（Free Space）和已经插入的数据（Inserted Tuples）三部分组成，表头在页中从左往右扩展，记录了 PrevPageId、NextPageId、FreeSpacePointer 以及每条记录在 TablePage 中的偏移和长度；插入的记录在页中从右向左扩展，每次插入记录时会将 FreeSpacePointer 的位置向左移动。

3.2.4 Index Manager

Index Manager 负责索引的管理，主要功能包括：包括：索引（B+ 树等形式）的创建和删除，索引键的等值查找，索引键的范围查找（返回对应的迭代器），以及插入和删除键值等操作，并对外提供相应的接口。

为了提高搜索的效率，我们实现基于磁盘的 B+ 树动态索引结构。首先完成 b+ 树数据结构的实现，然后建立在此基础上建立索引。B+ 树索引中的节点大小应与缓冲区的数据页大小相同，B+ 树的叉数由节点大小与索引键大小计算得到。

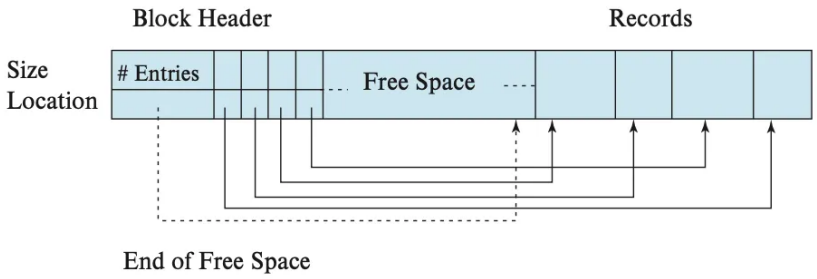

Figure 13.6 Slotted-page structure.

图 5: Table Page 结构

我们定义了`IndexRootsPage`来存储所有 Index 的 b+ 树的根节点的信息，主要包括 index_id, root_page_id 等等，用于在系统启动时加载所有的索引。

为了给 executor 提供使用接口，我们实现了迭代器用于索引的查找操作。在后续的开发中，我们只需要通过 BPlusTree 类的 Begin 和 End 方法来获取迭代器，然后通过迭代器来遍历 B+ 树中的键值对。

3.2.5 Catalog Manager

Catalog Meta catalog 是用来管理表和索引的数据信息的。表和索引的数据以 tableInfo 和 indexInfo 的类存储，这个类中包含表和索引的元信息 metadata 以及一些需要反序列化存储的信息。每张表和索引将存储在一张单独的 page 中，这个 page 存储的是对应表或索引序列化后的数据。而为了记录每张表和索引储存在那张 page 上，还需要一张总 page 来记录每张表和索引与各自 page 的对应关系，这张总 page 上的数据即为 catalogMeta, 其信息以序列化的形式储存在数据库的 CATALOG_META_PAGE_ID 数据页中，CATALOG_META_PAGE_ID 的值为零。

Catalog Manager catalogManager 用来管理目录元信息和数据页中表和索引的信息。当其初始化时，会加载元数据，把 tableInfo 和 indexInfo 放在内存中等待使用。通过 catalogManager 类里的方法可以对表与索引进行操作，包括创建、删除等。这些方法可以由上层模块调用，获取表与索引中的信息。

catalogManager 可以调用 buffer pool manager 的方法，获取与存储各种元数据；同时会被 executor 调用，进行表与索引的增删。

3.2.6 Planner and Executor

这个模块负责执行输入的 sql 语句。首先解释器 parser 用输入的 SQL 语句生成语法树，然后简单的语法树可以直接处理，复杂的语法树例如插入、删除等交由 planner 生成计划树，将一系列计划交给 executor 执行。

Planner Planner（执行计划生成器）的主要功能是根据解释器（Parser）生成的语法树，通过 Catalog Manager 提供的信息检查语法树中的信息是否正确，如表、列是否存在，谓词的值类型是否与 column 类型对应等等，随后将这些词语转换成可以理解的各种 c++ 类。解析完成后，Planner 根据改写语法树后生成的 Statement 结构，生成对应的 Plannode，并将 Plannode 交由 Executor 进行执行。

Executor Executor（执行器）的主要功能是遍历 Planner 生成的计划树，将树上的 PlanNode 替换成对应的 Executor，并调用 Record Manager、Index Manager 和 Catalog Manager 提供的相应接口进行执行。Executor 采用的是火山模型，提供迭代器接口，每次调用时会返回一个元组和相应的 RID，直到执行完成。本实验中 executor 模块采用的算子执行模型为火山模型，即 iterator model。每个算子有两个方法：init 和 next，init 进行初始化，next 向下层算子请求下一条数据。next 的返回类型为 bool，当返回 false 时说明没有下一条数据，执行结束。

3.2.7 SQL Parser

程序流程控制，即"启动并初始化 → '接收命令、处理命令、显示命令结果'循环 → 退出"流程。接收并解释用户输入的命令，生成命令的内部数据结构表示，同时检查命令的语法正确性和部分语义正确性，对正确的命令生成语法树，然后调用执行器层提供的函数执行并显示执行结果，对不正确的命令显示错误信息。

3.2.8 Recovery Manager

Recovery Manager 负责管理和维护数据恢复的过程, 实现一个纯内存的数据恢复模块即可，包括：

- 日志结构的定义
- 检查点 CheckPoint 的定义
- 执行 Redo、Undo 等操作，处理插入、删除、更新，事务的开始、提交、回滚等日志，将数据库恢复到宕机之前的状态

日志在内存中以 LogRec 的形式表现. 本实验不考虑日志的落盘,用一个 unordered_map 简易的模拟一个 KV Database，并直接在内存中定义一个能够用于插入、删除、更新，事务的开始、提交、回滚的日志结构。那么数据的恢复就很简单，redo 的事务可以直接对内存进行插删等操作来进行即可。

思考题 本模块中，为了简化实验难度，我们将 Recovery Manager 模块独立出来。如果不独立出来，真正做到数据库在任何时候断电都能恢复，同时支持事务的回滚，Recovery Manager 应该怎样设计呢？此外，CheckPoint 机制应该怎样设计呢？

- 首先是 LogRec 的结构,不再是 target_key 和 target_val,应该包含 table_name,index_name,rid,column 等,LogRecType 也应该更加细化,例如 kDelete 要细分为 kDeleteFromTable,kDeleteRow。
- Redo,Undo,Rollback 时,不能直接修改,而是调用 Catalog Manager 以及 table_heap 的函数来实现, 比如删除某一条数据时:(如果是回滚事务, 需要调用 table_heap 中的 RollbackDelete() 函数)

```
1    TableInfo *table_info;
2    dbs_[current_db_]->catalog_mgr_->GetTable(log_rec.table_name,table_info);
3    table_info->GetTableHeap()->MarkDelete(log_rec.rid,log_rec.txn);
```

- 创建日志的函数要根据 LogRec 结构的修改做出对应的修改，在执行器执行语句时需要调用这些函数创建日志。
- 要专门有一张 Page 记录日志，当发生 crash 后需要将日志 Load 上来。参考 table 和 index 的记录方式，可以对日志进行序列化和反序列化操作。
- 采用 Fuzzy Checkpoint，Innodb 每次取最老的 modified page(last checkpoint) 对应的 LSN，再将此脏页的 LSN 作为 Checkpoint 点记录到日志文件，意思就是“此 LSN 之前的 LSN 对应的日志和数据都已经 flush 到 redo log。当 mysql crash 的时候，Innodb 扫描 redo log，从 last checkpoint 开始 apply redo log 到 buffer pool，直到 last checkpoint 对应的 LSN 等于 Log flushed up to 对应的 LSN，则恢复完成。

4 测试样例和功能测试

4.1 测试样例

我们修改的测试用例包括，详尽的修改见个人报告:

- lab1：CLOCKReplacerTest
- lab2：TableHeapTest
- lab3: BPlusTreeTest

下面是测试的结果:
全部的样例测试都通过。

```
[----------] Global test environment tear-down
[==========] 21 tests from 11 test suites ran. (27068 ms total)
[  PASSED  ] 21 tests.
```

图 6: 测试结果

4.2 功能测试

我们对 MiniSQL 进行了功能测试，测试了 MiniSQL 的各个功能，包括：

```
create database db0;
use db0;
create table account(
    id int,
    name char(16) unique,
    balance float,
    primary key(id)
);

execfile "../sql_gen/account00.txt";
execfile "../sql_gen/account01.txt";
execfile "../sql_gen/account02.txt";
execfile "../sql_gen/account03.txt";
execfile "../sql_gen/account04.txt";
execfile "../sql_gen/account05.txt";
execfile "../sql_gen/account06.txt";
execfile "../sql_gen/account07.txt";
execfile "../sql_gen/account08.txt";
execfile "../sql_gen/account09.txt";
select * from account;

select * from account where id = 12512345;
select * from account where balance = 13;
select * from account where name = "name56789";
select * from account where name = "name01234";
select * from account where id < 12500005;
select * from account where id > 12599948;
select * from account where name < "name00037";
select * from account where name > "name99963";
select * from account where balance < 50;
select * from account where balance > 500;

select id, name from account where balance >= 100 and balance < 102;
select name, balance from account where balance > 100 and id <= 12500040;
select * from account where id < 12515000 and name > "name14500"
```

```
select * from account where id < 12500200 and name < "name00100"

insert into account values(12500004, "name00004", 4.87);
insert into account values(12500004, "name0", 4.87);
insert into account values(12500, "name00004", 4.87);

create index idx01 on account(name);
select * from account where name = "name56789";
select * from account where name = "name45678";
select * from account where id < 12500200 and name < "name00100";
delete from account where name = "name45678";
insert into account values(12314, "name45678", 666);
drop index idx01;
select * from account where name = "name45678";

update account set id = 125666, balance = 10 where name = "name56789";
select * from account where name = "name56789";
select * from account where id = 125666;

select * from account where balance = 123;
delete from account where balance = 123;
select * from account where balance = 123;

delete from account;
select * from account;

drop table account;
show tables;
```

其中大部分操作在验收时已经演示过了，这里着重比较一下插入的时间：在已经插入的条数的基础上每次插入 10000 条。下面是在 release 模式下的插入:

条数	0	10000	20000	30000	40000	50000	60000	70000	80000	90000
时间	0.608s	0.708s	0.868s	1.018s	1.095s	1.234s	1.295s	1.424s	1.525s	1.668s

表 2: release 插入时间

下面是在 debug 模式下的插入：

条数	0	10000	20000	30000	40000	50000	60000	70000	80000	90000
时间	3.43s	5.19s	7.40s	8.78s	10.58s	12.33s	14.72s	16.06s	18.26s	19.76s

表 3: debug 插入时间

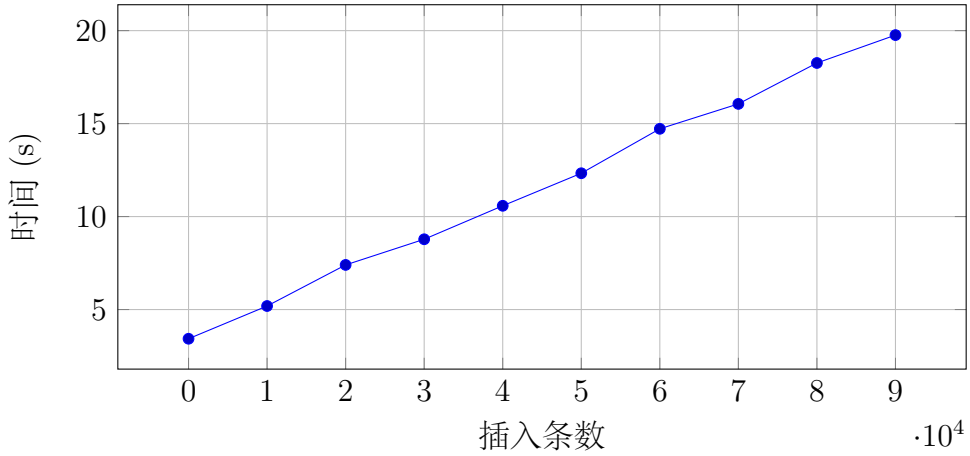

在图4.2中可以看到，随着插入的条数增加，插入的时间也在增加

再者我们验证了索引的功能，通过创建索引，我们可以加快查询的速度，如下图7所示（为了对比更加明显，我们在 debug 模式下运行）：

添加索引后，查询的速度明显加快。其余的操作都能够正常执行。

```
minisql > select * from account where name = "name00000";
[INFO] Sql syntax parse ok!
+---------+-----------+-------------+
| id      | name      | balance     |
+---------+-----------+-------------+
| 1250000 | name00000 | 514.349976 |
+---------+-----------+-------------+
1 row in set(0.0010 sec).
minisql > drop index i0;
[INFO] Sql syntax parse ok!
Index not exists.
minisql > show indexes;
[INFO] Sql syntax parse ok!
+--------------------+
| Indexes_in_account |
+--------------------+
| account_PK_IDX     |
+--------------------+
| idx01              |
+--------------------+
minisql > drop index idx01;
[INFO] Sql syntax parse ok!
index idx01 dropped.
minisql > select * from account where name = "name00000";
[INFO] Sql syntax parse ok!
+---------+-----------+-------------+
| id      | name      | balance     |
+---------+-----------+-------------+
| 1250000 | name00000 | 514.349976 |
+---------+-----------+-------------+
1 row in set(0.6410 sec).
```

图 7: 索引加速查询

5 总结

我们基本上完成了实验的要求，系统能够正常的运行并能够按预期输出，整个系统的工作量还是非常大的，而且调试起来也有一定的困难。验收时我们也演示了系统的功能，系统能够正常的运行，能够完成基本的增删改查操作，能够通过索引来优化性能。我们增添了许多测试，完善的单元测试可以减小后期整合系统的调试压力。我们也对系统进行了功能测试，系统能够正常的运行，能够完成上述的所有操作，尽管可能还存在一些 bug，但是基本上算是完整地实现了 minisql 这个程序。